

# KL vanishing 问题的一般解

本文主要针对阿里最近发表于 ICASSP2019 上的一篇论文“Improve Diverse Text Generation by Self Labeling Conditional Variational Auto Encoder”<sup>[1]</sup>, 通过博弈论的角度分析这篇论文存在的一些问题, 并给出了 KL vanishing 问题的一般解。因此, 本文的贡献主要包含了两方面:

1. 尝试从博弈论的角度分析 KL vanishing problem 的纳什均衡解, 并从这个角度得出阿里的这篇论文并不能很好地解决 KL vanishing problem
2. 从原始的 VAE 优化函数出发, 通过引入互信息的限制条件来解决 KL vanishing problem, 并从博弈论角度给出文本提出的优化算法的纳什均衡解不会再遇到 KL vanishing 问题

## KL vanishing problem

在 VAE 里面, KL vanishing problem 主要是指当  $KL(q(z|x) \parallel p(z))$  消失时, 并且当隐变量  $z$  和  $x$  独立时, 此时的  $ELBO = \log(p(x))$  【推导过程见 Supplemental Materials】。由  $KL(q(z|x) \parallel p(z|x)) = \log(p(x)) - ELBO$ , 得到此时  $KL(q(z|x) \parallel p(z|x)) = 0$ , 因此得出  $q(z|x) = p(z|x)$ , 但这个解并不是我们需要的理想解, 因为此时的互信息  $I(x, z) = 0$ 。

## 从博弈论观点看待 KL vanishing problem

通过对 KL vanishing problem 的分析，假设当  $KL(q(z|x) \parallel p(z))=0$  时，存在着两种情况，一个是  $z$  与  $x$  独立，另一个是  $z$  和  $x$  不独立。我们想得到的解是当  $KL(q(z|x) \parallel p(z))=0$  时， $z$  和  $x$  不独立。现在我们引入博弈论的思想，假设模型的两个 modules 之间进行博弈，它们分别是决定  $z$  和  $x$  独立与否的 module A，以及决定  $q(z|x)$  于  $p(z)$  是否相等的 module B。而它们的收益函数都是 ELBO 或 ELBO 的相关变种。

首先对传统 VAE 进行分析，得到 module A 和 module B 的收益矩阵【计算过程见 Supplemental Materials】：

Module A \ Module B	$q(z x) == p(z)$	$q(z x) \neq p(z)$
$z$ 与 $x$ 独立	$(\log p(x), \log p(x))$	$(\log p(x) - KL(q(z), p(z)), \log p(x) - KL(q(z), p(z)))$
$z$ 与 $x$ 不独立	$(E_{p(z)}[\log p(x z)], E_{p(z)}[\log p(x z)])$	$(ELBO, ELBO)$

由于  $E_{p(z)}[\log p(x|z)] \leq \log p(x)$ ，当且仅当  $x$  和  $z$  独立时等式成立，因此可以得到纳什均衡解是( $z$  与  $x$  独立,  $q(z|x) == p(z)$ )，此时就会造成所谓的 KL vanishing problem。

而“Improve Diverse Text Generation by Self Labeling Conditional Variational Auto Encoder”<sup>[1]</sup>这篇论文提出通过引入新的损失函数：

$$\begin{aligned} \mathcal{L}_{SLVAE} = & -\mathbb{E}_{q(z|x)}[\log p(x|z)] + KL(q(z|x) \parallel p(z)) \\ & + \lambda \mathbb{E}_{q(z|x)}[\|z - g(x)\|^2] \end{aligned}$$

可以避免出现 KL vanishing problem。他们的基本思想是，通过使隐变量  $z$  包含  $x$  的信息，从而避免模型收敛到( $z$  与  $x$  独立,  $q(z|x) == p(z)$ )这个解。但这种方法并不能完全避免模型收敛到( $z$  与  $x$  独立,  $q(z|x) == p(z)$ )。我们先一般化这个思路，即定义新的  $ELBO' = ELBO + f(x, z; \pi)$ ，具体的，这里的

$f(x, z; \pi) = -\lambda E_{q(z|x)}[||z - g(x)||^2]$ ，此处的  $\pi$  就是

module A 和 module B 采取的策略，即 module A 选择  $z$  是否与  $x$  独立，module

B 选择  $q(z|x)$  是否等于  $p(z)$ 。由此，我们得到新的收益矩阵：

Module A \ Module B	$q(z x) == p(z)$	$q(z x) \neq p(z)$
$z$ 与 $x$ 独立	$(\log p(x) + f(x, z; \pi_{0,0}), \log p(x) + f(x, z; \pi_{0,0}))$	$(\log p(x) - KL(q(z), p(z)) + f(x, z; \pi_{0,1}), \log p(x) - KL(q(z), p(z)) + f(x, z; \pi_{0,1}))$
$z$ 与 $x$ 不独立	$(E_{p(z)}[\log p(x z)] + f(x, z; \pi_{1,0}), E_{p(z)}[\log p(x z)] + f(x, z; \pi_{1,0}))$	$(ELBO + f(x, z; \pi_{1,1}), ELBO + f(x, z; \pi_{1,1}))$

因为要想让模型收敛到纳什均衡解( $z$  与  $x$  不独立， $q(z|x) == p(z)$ )，必须满足：

$$\begin{cases} E_{p(z)}[\log p(x|z)] + f(x, z; \pi_{1,0}) > \log p(x) + f(x, z; \pi_{0,0}) & (1) \\ E_{p(z)}[\log p(x|z)] + f(x, z; \pi_{1,0}) > ELBO + f(x, z; \pi_{1,1}) & (2) \end{cases}$$

但是当  $f(x, z; \pi) = -\lambda E_{q(z|x)}[||z - g(x)||^2]$  时，由于

$$f(x, z; \pi_{0,0}) = f(x, z; \pi_{1,0}) = -\lambda E_{p(z)}[||z - g(x)||^2]$$

，而当  $z$  与  $x$  不独立时， $E_{p(z)}[\log p(x|z)] < \log p(x)$ ，故条件(1)

不成立。因此此时的纳什均衡解依然是( $z$  与  $x$  独立， $q(z|x) == p(z)$ )。所以论文里

提出的算法并不能解决 KL vanishing problem。

## 新方法

我们发现如果尝试去通过修改中间优化函数，比如 ELBO，往往会导致最终得到的新的 objective function 不再和最原始的 objective function:  $\min KL(q(z|x), p(z|x))$  等价，这样的 objective function 往往是一个四不像，虽然从局部分析往往对模型有利，但如果从全局进行分析就会发现这样做会顾此失彼。因此，能否在原始的 objective function 上做修改，比如引入一个限制条件，使得隐变量  $z$  和  $x$  的互信息大于某个常数，这样我们能够保证求得

到的解与求解原始 objective function 等价。

## 定义新的 objective function

由于 VAE 最初的目标是优化  $KL(q(z|x), p(z|x))$ , 而我们只要在优化过程中引入一些限制条件, 比如使得  $x$  和  $z$  的互信息  $I(x, z) \geq c$ , 因此得到下面新的 objective function:

$$\begin{aligned} \min \quad & KL(q(z|x), p(z|x)) \\ \text{s.t.} \quad & I(x, z) \geq c \end{aligned}$$

通过引入拉格朗日乘子, 得到不带约束的优化问题:

$$\begin{aligned} \min \quad & \max_{\lambda} \quad KL(q(z|x), p(z|x)) + \lambda(c - I(x, z)) \quad \lambda \geq 0 \\ & \approx KL(q(z|x), p(z|x)) + \lambda \max(c - I(x, z), 0) \end{aligned}$$

我们可以看出, 这个优化目标函数可以使得当  $I(x, z) < c$  时, 将得到一个惩罚项, 只有当  $I(x, z) \geq c$  时, 惩罚项才为 0。

由

$$KL(q(z|x), p(z|x)) = \log p(x) - ELBO$$

因此, 若  $I(x, z) \geq c$ , 则

$$\begin{aligned} \min \quad & KL(q(z|x), p(z|x)) + \lambda \max(c - I(x, z), 0) \\ & \iff KL(q(z|x), p(z|x)) \\ & \iff \min \quad -ELBO + \log p(x) \quad (3) \end{aligned}$$

而当  $I(x, z) < c$  时, 由

$$\begin{aligned} I(x, z) &= KL(q(x, z), p(x)p(z)) \\ &= E_{p(x)}[KL(q(z|x), p(z))] \end{aligned}$$

进一步得到:

$$\begin{aligned} \min \quad & KL(q(z|x), p(z|x)) + \lambda \max(c - I(x, z), 0) \\ & \Rightarrow KL(q(z|x), p(z|x)) + \lambda(c - I(x, z)) \\ & \Rightarrow \log p(x) - ELBO + \lambda(c - E_{p(x)}[KL(q(z|x), p(z))]) \\ & \Rightarrow -ELBO - \lambda E_{p(x)}[KL(q(z|x), p(z))] + \lambda c + \log p(x) \\ & \Rightarrow -ELBO - \lambda E_{p(x)}[KL(q(z|x), p(z))] + \text{const} \quad (4) \\ & \quad \text{where} \quad \text{const} = \lambda c + \log p(x) \end{aligned}$$

在实际训练的时候, 我们让:

$$E_{p(x)}[KL(q(z|x), p(z))] \approx \frac{\sum_{i=1}^n KL(q(z|x_i), p(z))}{n}$$

因此新的求解算法具体过程如下:

1. Choose hyper-parameters:  $\lambda, c$ , and initialize model parameters  $\theta$  randomly
- 2.

While not stopped:

Sample a mini-batch data:  $\{x_1, x_2, \dots, x_n\}$

Calculate mini-batch mean  $KL(q(z|x), p(z))$ :

$$\overline{KL(q(z|x), p(z))} = \frac{\sum KL(q(z|x_i), p(z))}{n}$$

$$if \quad \overline{KL(q(z|x), p(z))} \geq c$$

Calculate gradients:

$$\nabla_{\theta} - ELBO$$

$$if \quad \overline{KL(q(z|x), p(z))} < c$$

Calculate gradients:

$$\nabla_{\theta} - ELBO - \lambda \overline{KL(q(z|x), p(z))}$$

Update model parameters  $\theta$

# 算法分析

文本提出的优化算法的收益矩阵为【计算过程见 Supplemental Materials】:

Module A \ Module B	$q(z x) == p(z)$	$q(z x) \neq p(z)$
$l(x, z) < c$	$(E_{p(z)}[\log p(x z)] - \lambda c - \log p(x)$ $, E_{p(z)}[\log p(x z)] - \lambda c - \log p(x))$	$(ELBO + \lambda E_{p(x)}[KL(q(z x), p(z))] - \lambda c - \log p(x)$ $, ELBO + \lambda E_{p(x)}[KL(q(z x), p(z))] - \lambda c - \log p(x))$
$l(x, z) \geq c$	$(E_{p(z)}[\log p(x z)] - \log p(x)$ $, E_{p(z)}[\log p(x z)] - \log p(x))$	$(ELBO - \log p(x)$ $, ELBO - \log p(x))$

特别的，当  $I(x, z)=0$ ，并且  $q(z|x) == p(z)$  时  $E_{p(z)}[\log p(x|z)] - \lambda c - \log p(x)$  的值取最大：

$$\begin{aligned} \max \quad & E_{p(z)}[\log p(x|z)] - \lambda c - \log p(x) \\ & = -\lambda c \end{aligned}$$

根据收益矩阵可以得出，我们只要满足条件：

$$\begin{cases} E_{p(z)}[\log p(x|z)] - \log p(x) > -\lambda c & (5) \\ \lambda E_{p(x)}[KL(q(z|x), p(z))] - \lambda c < 0 & (\text{where } I(x, z) < c, \quad q(z|x) \neq p(z)) \end{cases} \quad (6)$$

而这两项条件只要我们设置合理的  $\lambda, c$  值就可以满足。此时的纳什均衡解为  $(I(x, z) \geq c, q(z|x) == p(z))$ ，而这正是我们希望得到的解，因为此时在保证  $q(z|x) == p(z)$  的同时， $x$  与  $z$  不独立。

## 与 $\beta$ -VAE 对比

我们知道 $\beta$ -VAE 可以学到比较好的解耦表示，即使得每个维度的隐变量  $z_i$  之间的相关度很小，但同时它会减小隐变量  $z$  与  $x$  之间的互信息<sup>[2]</sup>。因此会导致 reconstruction 网络性能的下降。由于 $\beta$ -VAE 只是简单地增大对  $KL(q(z|x), p(z))$  的惩罚，随着训练的进行，有可能会 push 隐变量的分布朝着跟  $x$  独立的分布的方向去优化。而本文提出的算法，可以动态去调整  $KL(q(z|x), p(z))$  的惩罚项，从而避免减小隐变量  $z$  和  $x$  之间的互信息。同时我们发现，在优化目标函数(3)和(4)里引入 $\beta(\beta > 1)$ 后，收益矩阵变为：

Module A \ Module B	$q(z x) == p(z)$	$q(z x) \neq p(z)$
$I(x, z) < c$	$(E_{p(z)}[\log p(x z)] - \lambda c - \log p(x), E_{p(z)}[\log p(x z)] - \lambda c - \log p(x))$	$(E_{q(z x)}[\log p(x z)] - \beta KL(q(z x), p(z)) + \lambda E_{p(x)}[KL(q(z x), p(z))] - \lambda c - \log p(x), E_{q(z x)}[\log p(x z)] - \beta KL(q(z x), p(z)) + \lambda E_{p(x)}[KL(q(z x), p(z))] - \lambda c - \log p(x))$
$I(x, z) \geq c$	$(E_{p(z)}[\log p(x z)] - \log p(x), E_{p(z)}[\log p(x z)] - \log p(x))$	$(E_{q(z x)}[\log p(x z)] - \beta KL(q(z x), p(z)) - \log p(x), E_{q(z x)}[\log p(x z)] - \beta KL(q(z x), p(z)) - \log p(x))$

此时依然只要满足条件：

$$\begin{cases} E_{p(z)}[\log p(x|z)] - \log p(x) > -\lambda c & (5) \\ \lambda E_{p(x)}[KL(q(z|x), p(z))] - \lambda c < 0 & (\text{where } I(x, z) < c, \quad q(z|x) \neq p(z)) \end{cases} \quad (6)$$

就可以得到纳什均衡解： $(I(x, z) \geq c, q(z|x) == p(z))$ ，并且此时也可以学到比较好的解耦表示。

## References

1. Zhang Y , Wang Y , Zhang L , et al. Improve Diverse Text Generation by Self Labeling Conditional Variational Auto Encoder[J]. 2019.
2. Chen R T Q, Li X, Grosse R, et al. Isolating Sources of Disentanglement in Variational Autoencoders[J]. 2018.

## Supplemental Materials

1. 当  $KL(q(z|x) || p(z))=0$ ，并且隐变量  $z$  和  $x$  独立时， $ELBO=\log p(x)$

Proof:

$$\begin{aligned}
 ELBO &= E_{q(z|x)}[\log p(x|z)] - KL(q(z|x), p(z)) \\
 &= E_{q(z|x)}[\log p(x|z)] (\because KL(q(z|x), p(z)) = 0) \\
 &= E_{p(z)}[\log p(x|z)] \\
 &\leq \log(E_{p(z)}[p(x|z)]) \quad (Jensen's \text{ inequality}) \\
 &= \log p(x)
 \end{aligned}$$

上面不等式等号成立的条件是隐变量  $z$  和  $x$  独立。因此  $ELBO=\log p(x)$ 。  
证毕。

2. 传统 VAE module A 和 module B 的收益矩阵(此处假设 module A 和 module B 的收益都是优化目标函数值，下同):

Module A \ Module B	$q(z x) == p(z)$	$q(z x) \neq p(z)$
$z$ 与 $x$ 独立	$(\log p(x), \log p(x))$	$(\log p(x) - KL(q(z), p(z)), \log p(x) - KL(q(z), p(z)))$
$z$ 与 $x$ 不独立	$(E_{p(z)}[\log p(x z)], E_{p(z)}[\log p(x z)])$	$(ELBO, ELBO)$

$$ELBO = E_{q(z|x)}[\log p(x|z)] - KL(q(z|x), p(z))$$

当隐变量  $z$  和  $x$  独立并  $q(z|x) == p(z)$ 时，由 1 得到此时  $ELBO=\log p(x)$



当隐变量  $z$  和  $x$  不独立并  $q(z|x) \neq p(z)$  时，即原始的 ELBO 值

当隐变量  $z$  和  $x$  独立并  $q(z|x) \neq p(z)$  时:

$$\begin{aligned} ELBO &= E_{q(z|x)}[\log p(x|z)] - KL(q(z|x), p(z)) \\ &= E_{q(z)}[\log p(x)] - KL(q(z), p(z)) \\ &= \log p(x) - KL(q(z), p(z)) \end{aligned}$$

当隐变量  $z$  和  $x$  不独立并  $q(z|x) = p(z)$  时:

$$\begin{aligned} ELBO &= E_{q(z|x)}[\log p(x|z)] - KL(q(z|x), p(z)) \\ &= E_{p(z)}[\log p(x|z)] - KL(q(z|x), p(z)) \\ &= E_{p(z)}[\log p(x|z)] \end{aligned}$$

3. 文本提出的优化算法的收益矩阵为:

Module A \ Module B	$q(z x) = p(z)$	$q(z x) \neq p(z)$
$l(x, z) < c$	$(E_{p(z)}[\log p(x z)] - \lambda c - \log p(x), E_{p(z)}[\log p(x z)] - \lambda c - \log p(x))$	$(ELBO + \lambda E_{p(x)}[KL(q(z x), p(z))] - \lambda c - \log p(x), ELBO + \lambda E_{p(x)}[KL(q(z x), p(z))] - \lambda c - \log p(x))$
$l(x, z) \geq c$	$(E_{p(z)}[\log p(x z)] - \log p(x), E_{p(z)}[\log p(x z)] - \log p(x))$	$(ELBO - \log p(x), ELBO - \log p(x))$

当  $l(x, z) \geq c$  时，收益函数为:

$$\begin{aligned} \min \quad & -ELBO + \log p(x) \\ \iff \max \quad & ELBO - \log p(x) \quad (3) \end{aligned}$$

当  $l(x, z) < c$  时，收益函数为:

$$\begin{aligned} \min \quad & -ELBO - \lambda E_{p(x)}[KL(q(z|x), p(z))] + const \\ \text{where} \quad & const = \lambda c + \log p(x) \\ \iff \max \quad & ELBO + \lambda E_{p(x)}[KL(q(z|x), p(z))] - const \quad (4) \end{aligned}$$



当  $I(\mathbf{x}, \mathbf{z}) < c$  并  $q(\mathbf{z}|\mathbf{x}) = p(\mathbf{z})$  时, 由(4)得:

$$\begin{aligned} ELBO + \lambda E_{p(\mathbf{x})}[KL(q(\mathbf{z}|\mathbf{x}), p(\mathbf{z}))] - const \\ = E_{p(\mathbf{z})}[\log p(\mathbf{x}|\mathbf{z})] - \lambda c - \log p(\mathbf{x}) \end{aligned}$$

特别的, 当  $I(\mathbf{x}, \mathbf{z})=0$  时值取最大,

$$\begin{aligned} \max E_{p(\mathbf{z})}[\log p(\mathbf{x}|\mathbf{z})] - \lambda c - \log p(\mathbf{x}) \\ = \log p(\mathbf{x}) - \lambda c - \log p(\mathbf{x}) \\ = -\lambda c \end{aligned}$$

当  $I(\mathbf{x}, \mathbf{z}) < c$  并  $q(\mathbf{z}|\mathbf{x}) \neq p(\mathbf{z})$  时, 由(4)得:

$$\begin{aligned} ELBO + \lambda E_{p(\mathbf{x})}[KL(q(\mathbf{z}|\mathbf{x}), p(\mathbf{z}))] - const \\ = E_{q(\mathbf{z}|\mathbf{x})}[\log p(\mathbf{x}|\mathbf{z})] - KL(q(\mathbf{z}|\mathbf{x}), p(\mathbf{z})) + \lambda E_{p(\mathbf{x})}[KL(q(\mathbf{z}|\mathbf{x}), p(\mathbf{z}))] - \lambda c - \log p(\mathbf{x}) \end{aligned}$$

当  $I(\mathbf{x}, \mathbf{z}) \geq c$  并  $q(\mathbf{z}|\mathbf{x}) = p(\mathbf{z})$  时, 由(3)得:

$$\begin{aligned} ELBO - \log p(\mathbf{x}) = E_{q(\mathbf{z}|\mathbf{x})}[\log p(\mathbf{x}|\mathbf{z})] - KL(q(\mathbf{z}|\mathbf{x}), p(\mathbf{z})) - \log p(\mathbf{x}) \\ = E_{p(\mathbf{z})}[\log p(\mathbf{x}|\mathbf{z})] - \log p(\mathbf{x}) \end{aligned}$$

当  $I(\mathbf{x}, \mathbf{z}) \geq c$  并  $q(\mathbf{z}|\mathbf{x}) \neq p(\mathbf{z})$  时, 由(3)得:

$$ELBO - \log p(\mathbf{x}) = E_{q(\mathbf{z}|\mathbf{x})}[\log p(\mathbf{x}|\mathbf{z})] - KL(q(\mathbf{z}|\mathbf{x}), p(\mathbf{z})) - \log p(\mathbf{x})$$